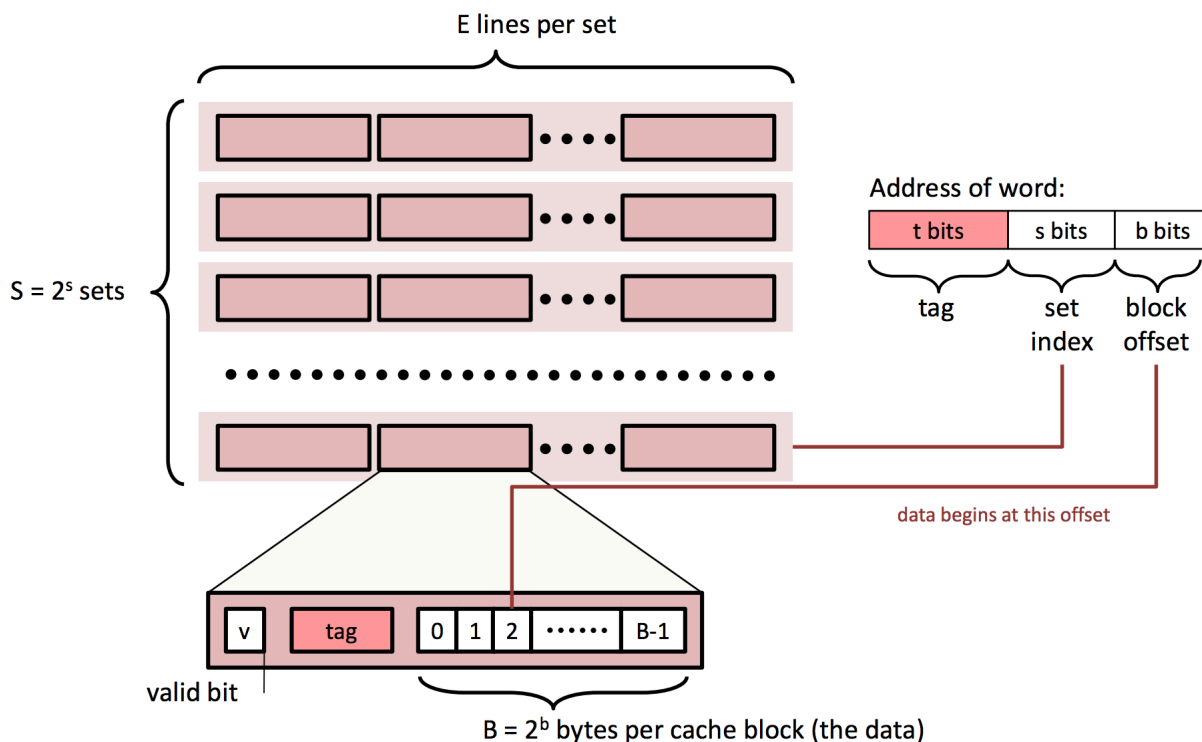


CacheLab

Part A C语言编程模拟Cache Memory

高速缓存的结构



在高速缓存中，我们把一块缓存分成 $S = 2^s$ 个 CacheSet，然后每个 CacheSet 中含有 E 个 CacheLine，CacheLine 就是在这个模型中最小的存储索引结构，含有 tag, valid, block 数据。他们的数据结构实现为：

```
struct CacheLine{
    int valid;
    unsigned long long int tag;
    char *data;
    int last_time;
};

struct CacheSet{
    struct CacheLine *lines;
};

struct Cache{
    struct CacheSet *sets;
};
```

数据结构从小往大设计，而初始化需要从大往小进行。

在c++中，我们可以使用 `cache.sets = new CacheSet [par.S]` 的语句来分配储存空间，但是在c中需要用malloc；另外，c中没有对象，不能对cache进行统一的封装，否则应该写一个大的Cache类把参数、函数都封装起来。

```
struct Cache initCache(struct CacheParameter par){
    struct Cache cache;
    cache.sets = (struct CacheSet*) malloc(sizeof(struct CacheSet) *
par.S);
    for(int i=0; i<par.S; i++){
        cache.sets[i].lines = (struct CacheLine*) malloc(sizeof(struct
CacheLine) * par.E);
        for(int j=0; j< par.E; j++){
            cache.sets[i].lines[j].valid = 0;
            cache.sets[i].lines[j].tag = 0;
            cache.sets[i].lines[j].last_time = 0;
        }
    }
    return cache;
}
```

数据读入读出

我第一次处理这种读入读出模式，根据我找到的资料，最终利用getopt.h等工具的帮助写成：

```
while( (c=getopt(argc,argv,"s:E:b:t")) != -1){
    switch(c){
        case 's':
            param.s = atoi(optarg);
            break;
        case 'E':
            param.E = atoi(optarg);
            break;
        case 'b':
            param.b = atoi(optarg);
            break;
        case 't':
            file = optarg;
            break;
    }
}
```

内存管理逻辑

根据书上的算法，在内存已满的情况下，我们需要把最不常用的数据替换掉，这里就需要我们来维护一个全局的时钟，在程序初试的时候设定为0。首先，用类似哈希算法将每个地址映射到一个CacheSet，`id_set = (addr >> param.b) & (param.S -1)`，然后在这个CacheSet里面遍历一遍，看看有没有已经存过了此数据，如果没存过再找一个空缺的/不常用的位置存起来。

```

unsigned int global_time;

int evictLine(struct CacheSet set) {
    //sequentially find the oldest cache line and evict it, time O(E)
    linear
    int min, min_id;
    min = set.lines[0].last_time;
    min_id = 0;
    for (int i=1; i<param.E; i++) {
        if (min > set.lines[i].last_time) {
            min_id = i;
            min = set.lines[i].last_time;
        }
    }
    return min_id;
}

void sim(struct Cache cache, unsigned long long int addr) {
    int empty = 0;

    unsigned long long int tag = addr >> (param.s + param.b);
    unsigned long long int id_set = (addr >> param.b) & (param.S -1);

    struct CacheSet cacheset = cache.sets[id_set];

    for (int i=0; i<param.E; i++) {
        if (cacheset.lines[i].valid) {
            if (cacheset.lines[i].tag == tag) {
                cacheset.lines[i].last_time = global_time ++;
                param.hits ++;
                return;
            }
        }
        else if (!(cacheset.lines[i].valid))
            empty = 1;
    }

    param.misses++;

    int min_id = evictLine(cacheset);
    if (!empty){
        param.evicts++;
        struct CacheLine *l = &cacheset.lines[min_id];
        l->tag = tag;
        l->valid = 1;
        l->last_time = global_time++;
    }
    else{
        struct CacheLine *l = &cacheset.lines[nextCacheLine(cacheset)];

```

```

        l->tag = tag;
        l->valid = 1;
        l->last_time = global_time++;
    }
}

```

结果

这个Cache模拟器通过了所有的样例：

Part A: Testing cache simulator							
[Running ./test-csim							
Points	(s,E,b)	Hits	Misses	Evicts	Hits	Misses	Evicts
3	(1,1,1)	9	8	6	9	8	6
3	(4,2,4)	4	5	2	4	5	2
3	(2,1,4)	2	3	1	2	3	1
3	(2,1,3)	167	71	67	167	71	67
3	(2,2,3)	201	37	29	201	37	29
3	(2,4,3)	212	26	10	212	26	10
3	(5,1,5)	231	7	0	231	7	0
6	(5,1,5)	265189	21775	21743	265189	21775	21743
27							

体会与展望

- 缓存的结构十分有趣，底层的算法优化可以大幅度提升计算机的性能
- 此算法单纯通过历史访问时间来判断，如果给每个数据添加不同的权重，那么还有其他的算法来优化
- 在这个作业中，E比较小，而且并没有设置时间上的限制，寻找最不常用的CacheLine的算法的时间复杂度是根据E线性的。如果E比较大的话，可以通过树或者堆的结构来将这一查询的时间复杂度降低到 $O(\log E)$ 。

Part B 优化矩阵转置

Cache分析

根据 `test-trans.c` 中的参数：

```

/* Check the performance of the student's transpose function */
eval_perf(5, 1, 5);

```

可以看到，这个cache是 $S = 32$ ， $E = 1$ ， $B = 32$ ，因为int是四子节的，所以每个CacheLine中会存储8个int。如果按照顺序排放，每个按列枚举的维度每八个数会重新load一遍，按行枚举的数每个都需要重新load一下，因此按这种情况得到的miss个数大约是 $\frac{9n}{8}$ ，根据实验（样例）情况，也确实如此。

分块

为了更好的局部性，我给矩阵分块，得到的结果如下，不同的分块方式适用于不同的矩阵大小：

	2*2	4*4	8*8	对角线优化
(32, 32)	727	487	343	287
(64, 64)	2899	1891	4723	1795
(61, 67)	3154	2443	2225	2112

```

if(M==32){
    for(block_i=0; block_i<32; block_i +=8){
        for(block_j=0; block_j<32; block_j +=8){
            for(i=block_i; i<block_i+8; i++){
                for(j=block_j; j<block_j+8; j++){
                    B[j][i] = A[i][j];
                }
            }
        }
    }
}

```

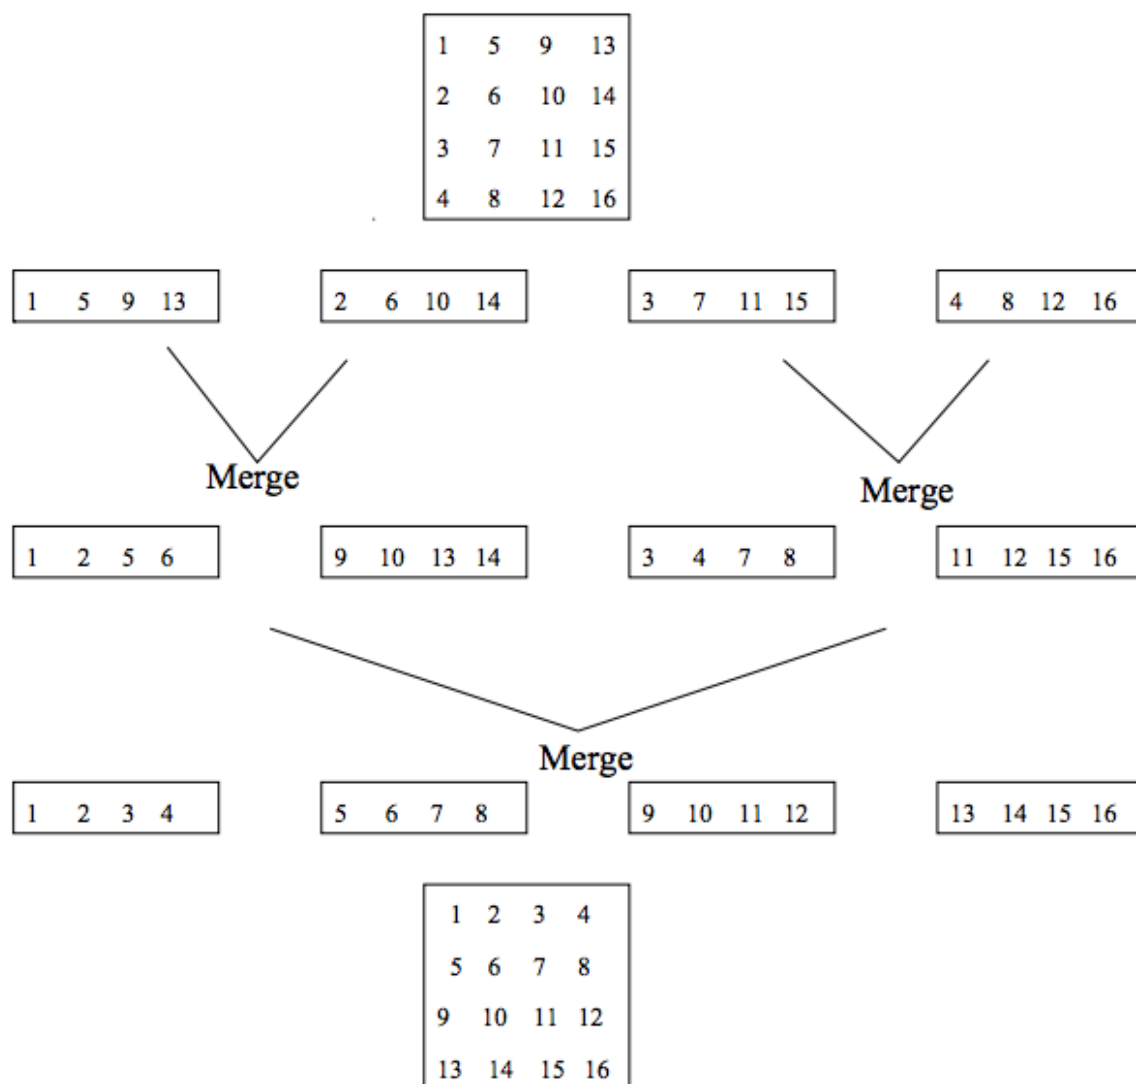
注意到对角线的元素不需要置换，所以我们可以更改求和顺序，使得性能提升一点，但是性能还是有一定的差距，特别是(64, 64)的矩阵。

```

for (ii = 0; ii < M; ii += 8){
    for (jj = 0; jj < N; jj += 8){
        for(i = ii; (i < M) && (i < ii + 8); i++){
            for(j=jj; (j<N) && (j < jj + 8); j++){
                if (i != j)
                    B[i][j] = A[j][i];
                else{
                    temp = A[j][i];
                    d = r;
                }
            }
            if(ii == jj)
                B[d][d] = temp;
        }
    }
}

```

Merge



注意到每个CacheLine里面可以存8个int，所以在如上分块的时候，可以进行连续两行之间的merge，来大幅度降低miss的数量。最终相比只有分块的情况下减少了大约两百多个miss。

Morton Ordering

影响缓存效率的一个原因在于，矩阵的存储中行是顺序存的，而列是间隔N存储的，在矩阵很大的情况下取一列的N个数会有N个miss。如果我们改变矩阵的index方式，可以缓解这个问题。但是因为实验要求不允许递归，所以我在提交的代码中并没有实现这个想法。

结果

```
Part B: Testing transpose function
Running ./test-trans -M 32 -N 32
Running ./test-trans -M 64 -N 64
Running ./test-trans -M 61 -N 67
```

Cache Lab summary:

	Points	Max pts	Misses
Csim correctness	27.0	27	
Trans perf 32x32	8.0	8	287
Trans perf 64x64	4.5	8	1603
Trans perf 61x67	8.9	10	2112
Total points	48.4	53	

参考文献

- 《深入理解计算机系统》Randel E. Bryant, David R. O'Hallaron
- Anthony E. Nocentino and Philip J. Rhodes. 2010. Optimizing memory access on GPUs using morton order indexing. In *Proceedings of the 48th Annual Southeast Regional Conference* (ACM SE '10). ACM, New York, NY, USA, , Article 18 , 4 pages. DOI=<http://dx.doi.org/10.1145/1900008.1900035>
- Chatterjee, S & Sen, Sandeep. (2000). Cache-efficient matrix transposition. IEEE High-Performance Computer Architecture Symposium Proceedings. 195-205. 10.1109/HPCA.2000.824350.